

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1

MÔN XỬ LÝ ẢNH

---



## **BÁO CÁO BÀI TẬP LỚN**

**Giải thích bài báo**

**“Adaptive Diffusion Priors  
for Accelerated MRI Reconstruction”**

**Giảng viên hướng dẫn**

**: Phạm Hoàng Việt**

**Họ và tên sinh viên**

**: Trần Gia Hiền**

**Mã sinh viên**

**: B22DCCN291**

**Lớp**

**: D22CNPM02 – N23**

*Hà Nội – 2025*

## MỤC LỤC

<b>1. Giới thiệu và lựa chọn bài báo</b>	<b>4</b>
<b>1.1. Tiêu đề, tác giả, nơi công bố, lý do chọn</b>	<b>4</b>
<b>2. Tóm tắt nội dung và phương pháp chính</b>	<b>4</b>
<b>2.1. Mục tiêu, bài toán và động cơ của nghiên cứu</b>	<b>4</b>
2.1.1. <i>Mục tiêu</i>	4
2.1.1.1. <b>Mục tiêu cốt lõi:</b> Cải thiện hiệu suất và độ tin cậy trước các thay đổi của điều kiện chụp	4
2.1.1.2. <b>Mục tiêu kỹ thuật 1:</b> Tăng tốc độ lấy mẫu ảnh	4
2.1.1.3. <b>Mục tiêu kỹ thuật 2:</b> Khắc phục hạn chế của "Tiền nghiệm tĩnh" (Static Priors)	5
2.1.2. <i>Bài toán</i>	5
2.1.2.1. <b>Bài toán cốt lõi:</b> Sự kém hiệu quả khi gặp "Thay đổi miền" (Domain Shifts)	5
2.1.2.2. <b>Bài toán kỹ thuật 1:</b> Các "Tiền nghiệm tĩnh" (Static Priors) hoạt động dưới mức tối ưu	6
2.1.2.3. <b>Bài toán kỹ thuật 2:</b> Tốc độ lấy mẫu chậm của mô hình khuếch tán	6
2.1.3. <i>Động cơ</i>	7
2.1.3.1. <b>Khắc phục khả năng "khái quát hóa kém" của các Mô hình có điều kiện (Conditional Models)</b>	7
2.1.3.2. <b>Giải quyết vấn đề "tốc độ chậm" của Mô hình Khuếch tán (Diffusion Models)</b>	8
2.1.3.3. <b>Cải thiện hiệu suất của các "Tiền nghiệm tĩnh" (Static Priors)</b>	8
<b>2.2. Thuật toán, mô hình, pipeline của bài báo</b>	<b>8</b>
2.2.1. <i>Thuật toán</i>	8
2.2.1.1. <b>Giai đoạn Huấn luyện: Xây dựng "Tiền nghiệm Khuếch tán Đối kháng" (Adversarial Diffusion Prior)</b>	9
2.2.1.2. <b>Giai đoạn Suy luận 1: Khuếch tán Nhanh (Rapid Diffusion Phase)</b>	10
2.2.1.3. <b>Giai đoạn Suy luận 2: Thích ứng Tiên nghiệm (Prior Adaptation Phase)</b>	10
2.2.2. <i>Mô hình</i>	11

2.2.3.	<i>Pipeline</i> .....	14
<b>3.</b>	<b>Đánh giá, phân tích và nhận xét</b> .....	17
3.1.	<b><i>Tính mới, ưu điểm và hạn chế của bài báo</i></b> .....	17
3.1.1.	<i>Tính mới</i> .....	17
3.1.2.	<i>Ưu điểm</i> .....	17
3.1.3.	<i>Hạn chế</i> .....	18
3.2.	<b><i>Góc nhìn cá nhân và hướng cải tiến</i></b> .....	18
3.2.1.	<i>Góc nhìn cá nhân</i> .....	19
3.2.2.	<i>Hướng cải tiến</i> .....	19
3.3.	<b><i>Ứng dụng thực tế</i></b> .....	20

## 1. Giới thiệu và lựa chọn bài báo

### 1.1. Tiêu đề, tác giả, nơi công bố, lý do chọn

- **Tiêu đề:** Adaptive Diffusion Priors for Accelerated MRI Reconstruction.  
→ Các Tiên nghiệm Khuếch tán Thích ứng để Tái tạo MRI Tăng tốc.
- **Nhóm tác giả:** Alper Güngör, Salman UH Dar, Şaban Öztürk, Yilmaz Korkmaz, Hasan A Bedel, Gokberk Elmas, Muzaffer Ozbey, Tolga Çukur đến từ Khoa Kỹ thuật Điện và Điện tử, Đại học Bilkent, Ankara 06800, Thổ Nhĩ Kỳ.
- **Nơi công bố:** Tạp chí Medical Image Analysis.
- **Lý do chọn:** Chụp MRI truyền thống bắt bệnh nhân phải nằm yên trong lòng máy ồn ào rất lâu (từ 30-60 phút). Bài báo này đề xuất một cách để rút ngắn thời gian chụp (Accelerated MRI) bằng cách chỉ cần thu thập một phần dữ liệu, nhưng vẫn tạo ra được bức ảnh hoàn chỉnh, sắc nét như khi chụp đủ thời gian.

## 2. Tóm tắt nội dung và phương pháp chính

### 2.1. Mục tiêu, bài toán và động cơ của nghiên cứu

#### 2.1.1. Mục tiêu

##### 2.1.1.1. Mục tiêu cốt lõi: Cải thiện hiệu suất và độ tin cậy trước các thay đổi của điều kiện chụp

Đây là mục tiêu quan trọng nhất. Nhóm tác giả muốn tạo ra một phương pháp tái tạo ảnh MRI không chỉ tốt trên dữ liệu giống với lúc huấn luyện, mà còn phải hoạt động tốt khi các điều kiện chụp (như tốc độ tăng tốc, quỹ đạo lấy mẫu, số lượng cuộn dây thu tín hiệu) bị thay đổi.

- **Dẫn chứng (Abstract):** "Tại đây, chúng tôi đề xuất tiên nghiệm khuếch tán thích ứng đầu tiên cho tái tạo MRI, AdaDiff, để cải thiện hiệu suất và độ tin cậy chống lại sự thay đổi miền (domain shifts)."
- **Dẫn chứng (Introduction):** "Tại đây, chúng tôi giới thiệu một phương pháp dựa trên khuếch tán mới, AdaDiff, để cải thiện hiệu suất và độ tin cậy chống lại sự thay đổi miền trong tái tạo MRI tăng tốc."

##### 2.1.1.2. Mục tiêu kỹ thuật 1: Tăng tốc độ lấy mẫu ảnh

Các mô hình khuếch tán truyền thống (như DDPM) rất chậm vì cần hàng nghìn bước để tạo ảnh. Bài báo đặt mục tiêu giải quyết vấn đề này bằng cách sử dụng cơ chế

"Adversarial Mapper" để thực hiện các bước nhảy lớn, giảm số bước cần thiết.

- **Dẫn chứng (Introduction):** “Thay vào đó, chúng tôi đề xuất một mô hình khuếch tán dựa trên bộ ánh xạ đối kháng (adversarial mapper) để tạo ra hình ảnh trong một vài bước khuếch tán ngược lớn nhằm tăng tốc đáng kể việc lấy mẫu hình ảnh.”
- **Dẫn chứng (Introduction):** "Tiên nghiệm khuếch tán đối kháng cho phép AdaDiff tái tạo hình ảnh chất lượng cao trong ít lần lặp suy luận hơn."

2.1.1.3. **Mục tiêu kỹ thuật 2:** Khắc phục hạn chế của "Tiên nghiệm tĩnh" (Static Priors)

Các phương pháp trước đây học một mô hình cố định và áp dụng cho mọi người. Mục tiêu của bài báo là tạo ra một mô hình có thể "tự điều chỉnh" (adapt) cho từng bệnh nhân cụ thể ngay trong quá trình suy luận để đạt kết quả tối ưu nhất.

- **Dẫn chứng (Abstract):** “Tuy nhiên, suy luận với một tiên nghiệm hình ảnh tĩnh có thể hoạt động dưới mức tối ưu.”
- **Dẫn chứng (Abstract):** "...một giai đoạn thích ứng tiếp tục tinh chỉnh kết quả bằng cách cập nhật tiên nghiệm để giảm thiểu mất mát về tính nhất quán dữ liệu."
- **Dẫn chứng (Introduction):** "AdaDiff học một tiên nghiệm khuếch tán vô điều kiện... và thích ứng tiên nghiệm khuếch tán này trong quá trình suy luận để nâng cao hiệu suất."

➔ Mục tiêu của bài báo là giới thiệu AdaDiff, một phương pháp vừa có khả năng thích ứng linh hoạt với các điều kiện chụp khác nhau (vượt trội hơn các mô hình tĩnh), vừa có khả năng chạy nhanh (vượt trội hơn các mô hình khuếch tán truyền thống).

2.1.2. *Bài toán*

2.1.2.1. **Bài toán cốt lõi:** Sự kém hiệu quả khi gặp "Thay đổi miền" (Domain Shifts)

Đây là "nỗi đau" lớn nhất của các mô hình Deep Learning trong y tế. Các mô hình thường học rất tốt trên tập dữ liệu

huấn luyện, nhưng khi mang ra thực tế, nếu điều kiện chụp thay đổi một chút, mô hình sẽ hoạt động kém hoặc thất bại.

- **Vấn đề cụ thể:** Các mô hình “có điều kiện” (conditional models – loại phổ biến nhất hiện nay) học cách khử nhiễu dựa trên kiến thức về toán tử chụp (imaging operator) lúc huấn luyện. Nếu khi kiểm tra (test), người dùng thay đổi toán tử này (ví dụ: đổi tốc độ chụp, mật độ lấy mẫu, số lượng cuộn dây), mô hình sẽ không thích nghi được.
- **Dẫn chứng (Abstract):** "Vì các mô hình có điều kiện được huấn luyện với kiến thức về toán tử hình ảnh, chúng có thể cho thấy khả năng khái quát hóa kém trên các toán tử thay đổi."
- **Dẫn chứng (Introduction):** "...sự thay đổi miền trong toán tử có thể làm tổn hại đến hiệu suất tái tạo và đòi hỏi phải đào tạo lại các mô hình có điều kiện."

2.1.2.2. **Bài toán kỹ thuật 1:** Các "Tiên nghiệm tĩnh" (Static Priors) hoạt động dưới mức tối ưu

- **Vấn đề cụ thể:** Một prior tĩnh không thể bao quát hết sự đa dạng của từng bệnh nhân cụ thể hoặc các thay đổi trong phân phối ảnh MR (do thay đổi xung chụp hoặc cài đặt máy quét).
- **Dẫn chứng (Abstract):** "Tuy nhiên, suy luận với một tiên nghiệm hình ảnh tĩnh có thể hoạt động dưới mức tối ưu."
- **Dẫn chứng (Theory):** "Tuy nhiên, các phương pháp tái tạo gần đây sử dụng các tiên nghiệm khuếch tán tĩnh có khả năng gây ra hiệu suất dưới mức tối ưu."

2.1.2.3. **Bài toán kỹ thuật 2:** Tốc độ lấy mẫu chậm của mô hình khuếch tán

Mô hình khuếch tán (Diffusion Models) tạo ra ảnh rất đẹp, nhưng nó quá chậm để ứng dụng lâm sàng thực tế nếu dùng cách truyền thống.

- **Vấn đề cụ thể:** Các mô hình khuếch tán thông thường (Vanilla diffusion models) cần hàng trăm đến hàng nghìn bước lặp để tạo ra một bức ảnh từ nhiễu.

- **Dẫn chứng (Introduction):** "Các mô hình khuếch tán Vanilla tạo ra hình ảnh thông qua một chuỗi dài các bước suy luận, dẫn đến việc lấy mẫu hình ảnh kéo dài."
  - **Dẫn chứng (Related Work):** "Mô hình khuếch tán Vanilla sử dụng hàng trăm bước ngược để tạo ảnh, làm tăng gánh nặng tính toán."
- **Bài toán tổng hợp mà bài báo giải quyết là:** Làm thế nào để tái tạo ảnh MRI nhanh và chất lượng cao mà vẫn đảm bảo tính ổn định (robustness) ngay cả khi điều kiện chụp hoặc thiết bị thay đổi (Domain Shifts), đồng thời khắc phục được tốc độ suy luận chậm chạp của các mô hình khuếch tán truyền thống?
- **Giải pháp của các tác giả chính là AdaDiff:** Dùng "Adversarial Mapper" để giải quyết bài toán tốc độ, và dùng "Prior Adaptation" để giải quyết bài toán Domain Shift.

### 2.1.3. Động cơ

Động cơ (motivation) của bài báo này xuất phát từ việc nhận diện và muốn khắc phục 3 hạn chế lớn của các phương pháp tái tạo MRI hiện có. Nhóm tác giả muốn tạo ra một mô hình không chỉ tốt về chất lượng ảnh mà còn phải linh hoạt (không cần huấn luyện lại khi thay đổi thiết bị) và nhanh chóng.

#### 2.1.3.1. Khắc phục khả năng "khái quát hóa kém" của các Mô hình có điều kiện (Conditional Models)

Các mô hình Deep Learning phổ biến hiện nay thường được huấn luyện "có điều kiện" dựa trên thông số máy quét cụ thể. Động cơ của tác giả là muốn thoát khỏi sự phụ thuộc này để mô hình có thể hoạt động tốt ngay cả khi thông số máy quét thay đổi (domain shifts).

- **Dẫn chứng (Abstract):** "Vì các mô hình có điều kiện được huấn luyện với kiến thức về toán tử hình ảnh (imaging operator), chúng có thể cho thấy khả năng khái quát hóa kém trên các toán tử thay đổi."
- **Dẫn chứng (Introduction):** "...sự thay đổi miền trong toán tử (ví dụ: thay đổi tỷ lệ tăng tốc, mật độ lấy mẫu...) có thể làm tổn hại đến hiệu suất tái tạo và đòi hỏi phải đào tạo lại các mô hình có điều kiện."

- **Dẫn chứng (Introduction):** "Để tránh những tổn thất tiềm ẩn trong hiệu suất khái quát hóa, các mô hình tái tạo sâu có khả năng phục hồi trước các biến thể trong toán tử hình ảnh là cực kỳ cần thiết."

#### 2.1.3.2. **Giải quyết vấn đề "tốc độ chậm" của Mô hình Khuếch tán (Diffusion Models)**

Mặc dù Mô hình Khuếch tán tạo ra ảnh rất đẹp và đa dạng, nhưng nó nổi tiếng là chậm chạp do cần quá nhiều bước để tạo ảnh. Động cơ của tác giả là muốn tận dụng sức mạnh của Diffusion nhưng phải làm cho nó nhanh hơn đáng kể.

- **Dẫn chứng (Abstract):** "Các mô hình khuếch tán Vanilla tạo ra hình ảnh thông qua một chuỗi dài các bước suy luận, dẫn đến việc lấy mẫu hình ảnh kéo dài."
- **Dẫn chứng (Related Work):** "Các mô hình khuếch tán Vanilla sử dụng hàng trăm bước ngược để tạo hình ảnh, làm tăng gánh nặng tính toán."

#### 2.1.3.3. **Cải thiện hiệu suất của các "Tiên nghiệm tĩnh" (Static Priors)**

Các phương pháp không điều kiện (unconditional) trước đây sử dụng một mô hình "tĩnh" (không thay đổi sau khi huấn luyện). Động cơ của tác giả là muốn mô hình phải "động", tức là tự điều chỉnh được cho từng ca bệnh cụ thể để đạt hiệu suất cao nhất.

- **Dẫn chứng (Abstract):** "Tuy nhiên, suy luận với một tiên nghiệm hình ảnh tĩnh có thể hoạt động dưới mức tối ưu."
- **Dẫn chứng (Theory):** "Tuy nhiên, các phương pháp tái tạo gần đây sử dụng các tiên nghiệm khuếch tán tĩnh có khả năng gây ra hiệu suất dưới mức tối ưu."

➔ Động cơ của bài báo là tạo ra một phương pháp "một mũi tên trúng 3 đích": (1) Bền vững trước sự thay đổi của thiết bị chụp, (2) Tốc độ xử lý nhanh, và (3) Tối ưu hóa chất lượng ảnh cho từng bệnh nhân cụ thể.

## 2.2. *Thuật toán, mô hình, pipeline của bài báo*


### 2.2.1. *Thuật toán*



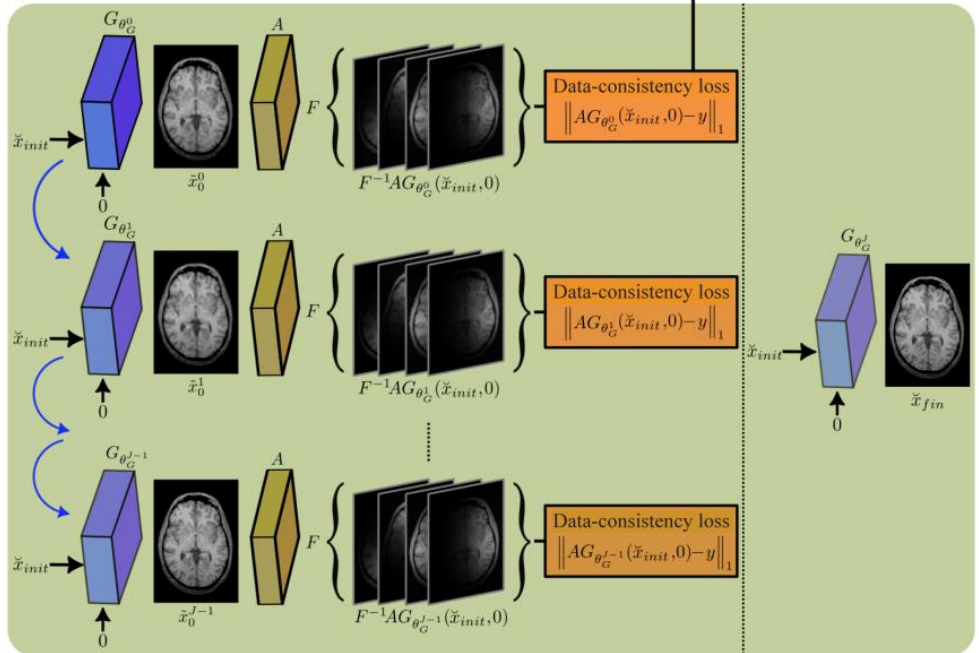
Thuật toán cốt lõi được đề xuất trong bài báo này có tên là AdaDiff (Adaptive Diffusion Prior).

Đây không phải là một thuật toán đơn lẻ mà là một quy trình (framework) gồm 3 giai đoạn kết hợp giữa huấn luyện mô hình sinh (generative model) và tối ưu hóa tại thời điểm suy luận.

**a) Rapid Diffusion**



**b) Prior Adaptation**



**2.2.1.1. Giai đoạn Huấn luyện: Xây dựng "Tiền nghiệm Khuếch tán Đối kháng" (Adversarial Diffusion Prior)**

Đây là giai đoạn chuẩn bị mô hình trước khi áp dụng vào thực tế.

- **Mục tiêu:** Học cách biến đổi một bức ảnh nhiễu (Gaussian noise) thành ảnh MRI sạch, nhưng phải làm điều đó thật nhanh (ít bước).
- **Vấn đề:** Các mô hình khuếch tán thông thường (Vanilla Diffusion) giả định các bước khử nhiễu là phân phối chuẩn (Gaussian), điều này chỉ đúng khi

bước nhảy thời gian cực nhỏ. Muốn nhảy bước lớn (để nhanh hơn), giả định này bị phá vỡ.

- **Thuật toán cụ thể:** Nhóm tác giả sử dụng một Adversarial Mapper (Bộ ánh xạ đối kháng). Thay vì dùng công thức toán học cố định, họ huấn luyện một mạng GAN để học bước nhảy ngược:
  - **Generator ( $G_{\theta_G}$ ):** Nhận vào ảnh nhiễu ở bước  $t + k$ , dự đoán ảnh gốc sạch  $x_0$ , từ đó suy ra trạng thái ít nhiễu hơn ở bước  $t$ .
  - **Discriminator ( $D_{\theta_D}$ ):** Phân biệt xem bước nhảy do Generator tạo ra có giống với quá trình khuếch tán thực tế hay không.
- **Hàm mất mát (Loss):** Sử dụng hàm mất mát đối kháng (adversarial loss) kết hợp với phạt gradient (gradient penalty).

#### 2.2.1.2. Giai đoạn Suy luận 1: Khuếch tán Nhanh (Rapid Diffusion Phase)

Đây là bước đầu tiên khi có dữ liệu bệnh nhân mới.

- **Mục tiêu:** Tạo ra một bản tái tạo ban đầu ( $x_{init}$ ) chất lượng cao trong thời gian ngắn.
- **Thuật toán:** Thực hiện vòng lặp (khoảng 8 bước) xen kẽ giữa hai thao tác:
  - **Reverse Diffusion Projection:** Dùng Generator đã huấn luyện ở trên để khử nhiễu một phần cho ảnh. Công thức:  $x_0 = G_{\theta_G}(x_{t+k}, t+k)$ .
  - **Data-Consistency Projection (DC):** Ép buộc ảnh vừa khử nhiễu phải khớp với dữ liệu k-space ( $y$ ) đã thu thập được. Công thức:  $x_{t+k} = x_{t+k} + A^H(y - A_{x_{t+k}})$
- **Kết quả:** Thu được một ảnh  $x_{init}$  khá tốt, là sự thỏa hiệp giữa kiến thức của mô hình và dữ liệu thực tế.

#### 2.2.1.3. Giai đoạn Suy luận 2: Thích ứng Tiên nghiệm (Prior Adaptation Phase)

Đây là bước quan trọng và độc đáo nhất của thuật toán này, giúp mô hình "thông minh" hơn với từng ca bệnh.

- **Mục tiêu:** Tinh chỉnh mô hình để khớp hoàn hảo với dữ liệu của bệnh nhân hiện tại, khắc phục lỗi do sự khác biệt về máy móc hoặc giải phẫu (domain shift).
- **Thuật toán:** Thay vì giữ nguyên trọng số của mạng Generator ( $G_{\theta_G}$ ) như các phương pháp truyền thống, AdaDiff thực hiện một vòng lặp tối ưu hóa (khoảng 1000 bước) để cập nhật lại trọng số này ngay trên dữ liệu đang xét.
- **Chi tiết thực hiện:**
  1. Lấy ảnh đầu ra từ Generator:  

$$\tilde{x} = G_{\theta_G}(\tilde{x}_{init}, 0)$$
  2. Đưa ảnh qua toán tử hình ảnh  $\mathcal{A}$  (mô phỏng quá trình chụp MRI bị thiếu dữ liệu) để tạo ra dữ liệu k-space giả định.
  3. Tính sai số (Loss) giữa dữ liệu giả định này và dữ liệu k-space thực tế  $y$  của bệnh nhân.
    - Công thức Loss:  

$$\theta_G^* = \min_{\theta_G} ||\mathcal{A}G_{\theta_G}(\tilde{x}_{init}, 0) - y||_1$$
  4. Dùng thuật toán tối ưu (như Adam) để cập nhật nhẹ các tham số  $\theta_G$  sao cho sai số này giảm xuống.
- **Kết quả cuối cùng:** Ảnh tái tạo cuối cùng  $\tilde{x}_{fin}$  được tạo bởi Generator với bộ trọng số đã được tinh chỉnh ( $\theta_G^*$ ).

#### Tóm tắt ngắn gọn về luồng thuật toán:

1. **Trước khi gặp bệnh nhân:** Dùng GAN để học cách khử nhiễu cực nhanh (Adversarial Training).
2. **Khi gặp bệnh nhân (Bước 1):** Dùng mô hình đã học để tạo nhanh một bản nháp (Rapid Diffusion).
3. **Khi gặp bệnh nhân (Bước 2):** So sánh bản nháp với dữ liệu thực tế, nếu thấy lệch thì sửa lại chính bộ não của mô hình (Prior Adaptation) để vẽ lại cho khớp.


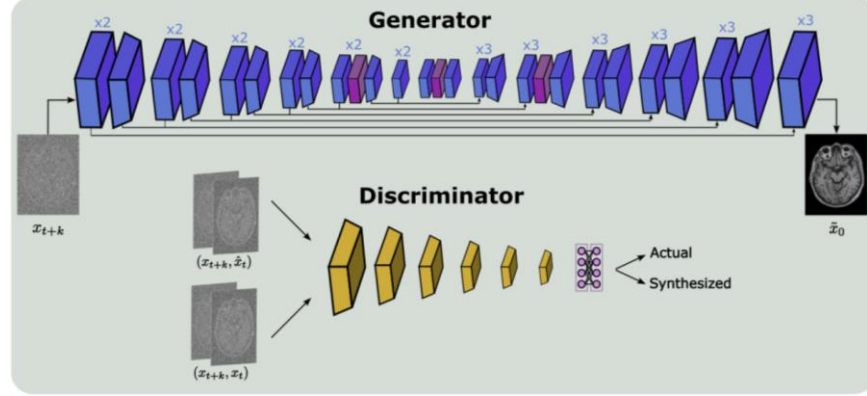
#### 2.2.2. Mô hình

Mô hình được đề xuất và là trọng tâm của bài báo này có tên là AdaDiff (Adaptive Diffusion Prior).

Đây là một mô hình kết hợp giữa Mạng Đối kháng Sinh (GAN) và Mô hình Khuếch tán (Diffusion Model), với kiến trúc mạng nơ-ron sâu phức tạp để giải quyết bài toán tái tạo MRI.

### 1. Kiến trúc Mạng (Network Architecture)

Mô hình AdaDiff không sử dụng một mạng đơn lẻ, mà sử dụng cấu trúc "Adversarial Mapper" (Bộ ánh xạ đối kháng) bao gồm hai mạng con chính: Generator (Bộ sinh) và Discriminator (Bộ phân biệt).



**A. Generator ( $G_{\theta_G}$ )**

Đây là "trái tim" của mô hình, chịu trách nhiệm tạo ra ảnh MRI sạch từ ảnh nhiễu.

- **Cấu trúc tổng thể:** Sử dụng kiến trúc Encoder-Decoder (Mã hóa - Giải mã) với các kết nối tắt (residual connections), tương tự như U-Net.
- **Đầu vào:**
  - Ảnh nhiễu ở bước thời gian  $t + k(x_{t+k})$ .
  - Chỉ số thời gian  $t$  (time index).
  - Một vectơ biến ẩn ngẫu nhiên
- **Chi tiết các khối (Blocks):**
  - *Phần Encoder:* Gồm 6 giai đoạn (stages). Mỗi giai đoạn có 2 khối dư (residual blocks) phẳng, theo sau là 1 khối dư giảm mẫu (downsampling) với hệ số 2.
  - *Phần Decoder:* Gồm 6 giai đoạn. Mỗi giai đoạn có 3 khối dư phẳng, theo sau là 1 khối dư tăng mẫu (upsampling) với hệ số 2.
  - *Cơ chế Attention:* Các lớp Attention được đặt ở 2 giai đoạn cuối của Encoder và giai đoạn thứ 2 của Decoder để mô hình tập trung vào các đặc trưng quan trọng.
- **Cơ chế Adaptive Normalization - AdaGN:** Đây là điểm kỹ thuật quan trọng. Các bản đồ đặc trưng (feature maps) trong mỗi khối không được chuẩn hóa theo cách thông thường, mà được điều biến (modulated) bởi vectơ ẩn  $z$  thông qua lớp Adaptive Group Normalization. Vectơ  $z$  này được xử lý qua một mạng MLP 8 lớp trước khi đưa vào.
- **Time Embeddings:** Thời gian  $t$  được mã hóa bằng hàm hình sin (sinusoidal encoding), sau đó qua mạng MLP 2 lớp và được cộng vào như một bias (độ lệch) cho từng kênh đặc trưng.
- **Activation Function:** SiLU.

## B. Discriminator ( $D_{\theta_D}$ )

Mạng này đóng vai trò "thầy giáo", giúp Generator học cách tạo ra các bước chuyển đổi khuếch tán thực tế.

- **Cấu trúc:** Sử dụng kiến trúc Residual Encoder.

- **Chi tiết các khối:** Gồm 6 giai đoạn, mỗi giai đoạn chứa một khối dư giảm mẫu (downsampling). Cuối cùng là một lớp MLP để đưa ra quyết định phân biệt.
- **Đầu vào:** Nhận vào một cặp ảnh để so sánh: cặp ảnh thực  $(x_{t+k}, x_t^{\wedge})$ .
- **Hàm kích hoạt:** Sử dụng hàm Leaky ReLU với độ dốc âm 0.2.

## 2. Cơ chế Hoạt động

Mô hình này hoạt động dựa trên việc giải quyết vấn đề của các mô hình khuếch tán truyền thống khi muốn chạy nhanh (bước nhảy thời gian lớn).

### Vấn đề lý thuyết

Trong mô hình khuếch tán thông thường (Vanilla Diffusion), xác suất chuyển đổi ngược  $q(x_t|x_{t+1})$  được giả định là phân phối chuẩn (Gaussian). Điều này chỉ đúng khi bước nhảy thời gian cực nhỏ. Khi muốn tăng tốc bằng cách nhảy bước lớn (ví dụ từ  $t+k$  về  $t$  với  $k$  lớn), giả định Gaussian bị phá vỡ.

### Giải pháp của AdaDiff

Thay vì dùng công thức Gaussian sai lệch, AdaDiff dùng mạng Generator để học phân phối chuyển đổi phức tạp này ( $p_{\theta_G}(x_t|x_{t+k})$ ).

- **Generator học:** Cố gắng sinh ra ảnh  $x_t$  từ  $x_{t+k}$  sao cho giống với quá trình khuếch tán thật.
- **Discriminator học:** Cố gắng phân biệt đâu là bước chuyển đổi thật (từ dữ liệu huấn luyện) và đâu là bước chuyển đổi giả (do Generator tạo ra).

### Quy trình huấn luyện

- **Discriminator ( $L_D$ ):** Tối thiểu hóa hàm mất mát đối kháng để phân biệt giỏi hơn.
- **Generator ( $L_G$ ):** Tối đa hóa khả năng đánh lừa Discriminator.
- Đặc biệt, Generator không dự đoán trực tiếp ảnh ở bước  $t$ , mà dự đoán ảnh gốc sạch  $x_0^{\sim}$ , từ đó suy ra  $x_t$  thông qua công thức hậu nghiệm (posterior formula) để đảm bảo tính ổn định.

#### 2.2.3. Pipeline

Pipeline của phương pháp AdaDiff được nhóm tác giả mô tả là một quy trình tái tạo gồm 2 pha (two-phase reconstruction).

Quy trình này được thiết kế để kết hợp tốc độ của mô hình khuếch tán nhanh (rapid diffusion) với độ chính xác của việc tinh chỉnh theo từng đối tượng (subject-specific adaptation).

### Tổng quan pipeline:

Quy trình hoạt động theo trình tự thời gian sau khi mô hình đã được huấn luyện xong:


1. **Đầu vào:** Dữ liệu k-space bị thiếu ( $y$ ) và mặt nạ lấy mẫu ( $\Omega$ ) của bệnh nhân.
2. **Pha 1 (Rapid Diffusion):** Tạo ra ảnh tái tạo sơ khởi.
3. **Pha 2 (Prior Adaptation):** Tinh chỉnh mô hình để tạo ra ảnh cuối cùng.

### Chi tiết từng giai đoạn:

#### 1. Pha 1: Khuếch tán Nhanh (Rapid Diffusion Phase)

Đây là giai đoạn khởi tạo, mục tiêu là tạo ra một bản tái tạo ban đầu ( $\tilde{x}_{init}$ ) có chất lượng tốt một cách nhanh chóng.

- **Cách hoạt động:** Pipeline thực hiện một chuỗi các bước lặp (khoảng 8 bước). Tại mỗi bước, nó thực hiện xen kẽ hai thao tác:
  - **Data-Consistency Projection (DC):** Chiếu ảnh hiện tại về không gian dữ liệu đo được để đảm bảo tính nhất quán vật lý.
  - **Reverse Diffusion Step:** Dùng mạng Generator ( $G_{\theta_G}$ ) để khử nhiễu và khôi phục các chi tiết bị mất, dựa trên kiến thức tiên nghiệm đã học
- **Kết quả đầu ra:** Một hình ảnh tái tạo ban đầu  $\tilde{x}_{init}$ .
- **Dẫn chứng:** Mục 3.3.2, đoạn văn bắt đầu bằng "Rapid diffusion: The rapid diffusion phase calculates..." (trang 6).

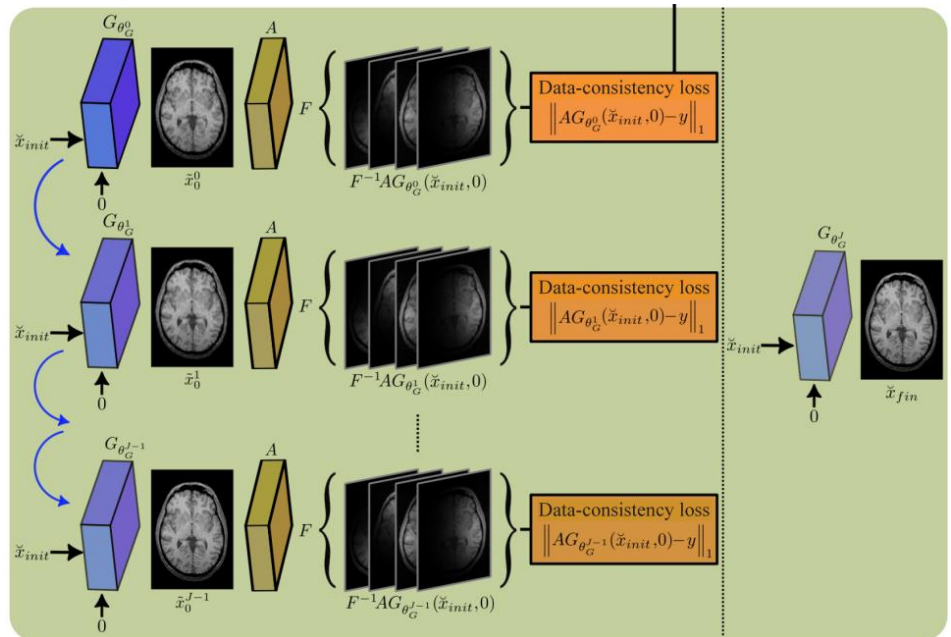


Hiển thị chuỗi các khối màu xanh (DC) và cam (Generator) nối tiếp nhau để tạo ra  $\tilde{x}_{init}$ .

#### 2. Pha 2: Thích ứng Tiên nghiệm (Prior Adaptation Phase)

Đây là giai đoạn tinh chỉnh, mục tiêu là làm cho mô hình "khớp" hoàn toàn với dữ liệu riêng biệt của bệnh nhân đang được xử lý.

- **Đầu vào:** Ảnh tái tạo ban đầu  $\tilde{x}_{init}$  từ Pha 1.
- **Cách hoạt động:** Pipeline chuyển sang chế độ tối ưu hóa (optimization loop).
  - Nó giữ cố định đầu vào  $\tilde{x}_{init}$ .
  - Nó thay đổi (cập nhật) trọng số của mạng Generator ( $\theta_G$ ) để cực tiểu hóa sai số giữa dữ liệu k-space do mạng sinh ra và dữ liệu k-space thực tế của bệnh nhân ( $y$ ).
  - Quá trình này lặp lại nhiều lần.
- **Kết quả đầu ra:** Hình ảnh tái tạo cuối cùng  $\tilde{x}_{fin}$ , được sinh ra bởi mạng Generator sau khi đã được tinh chỉnh.
- **Dẫn chứng:** Mục 3.3.2, đoạn văn bắt đầu bằng "Prior adaptation: Taking the initial reconstruction..." (trang 6).



Hiện thị vòng lặp tối ưu hóa (mũi tên xanh dương quay ngược về Generator) để cập nhật  $\theta_G$  dựa trên "Data-consistency loss".

➔ **Pipeline của AdaDiff** là sự nối tiếp của Pha tạo ảnh nhanh (dựa trên mô hình đã học) và Pha tinh chỉnh (dựa trên dữ liệu thực tế), giúp cân bằng giữa tốc độ và độ chính xác cá nhân hóa.



### 3. Đánh giá, phân tích và nhận xét

#### 3.1. Tính mới, ưu điểm và hạn chế của bài báo

##### 3.1.1. Tính mới

Bài báo này không chỉ đơn thuần là áp dụng một mô hình có sẵn vào dữ liệu mới, mà nó đề xuất những cải tiến kỹ thuật mang tính tiên phong trong lĩnh vực MRI:

- **Tiên nghiệm Khuếch tán Thích ứng đầu tiên cho MRI:**
  - Đây là đóng góp lớn nhất. Trước đây, người ta hoặc dùng mô hình "tĩnh" (học xong để đó), hoặc dùng mô hình "thích ứng" nhưng dựa trên GAN (kém đa dạng) hoặc mạng chưa huấn luyện (Deep Image Prior - rất chậm).
  - AdaDiff là phương pháp đầu tiên kết hợp sức mạnh của Diffusion Model với cơ chế "tinh chỉnh tại thời điểm suy luận" (inference-time adaptation) cho bài toán tái tạo MRI.
- **Cơ chế "Adversarial Mapper" cho bước nhảy thời gian lớn:**
  - Các mô hình khuếch tán truyền thống phải đi từng bước nhỏ (ví dụ  $t, t-1, t-2, \dots$ ) để đảm bảo giả định phân phối Gaussian.
  - AdaDiff đề xuất một cách mới: Sử dụng mạng GAN để mô phỏng phân phối chuyển đổi cho các bước nhảy lớn (ví dụ từ  $t$  xuống  $t-125$ ). Điều này cho phép mô hình "nhảy cóc" qua nhiều bước thời gian mà không làm hỏng chất lượng ảnh.
- **Quy trình tái tạo 2 pha:**
  - Sự kết hợp giữa pha Rapid Diffusion (để lấy cấu trúc tổng thể nhanh) và pha Prior Adaptation (để khớp chi tiết cụ thể với dữ liệu bệnh nhân) là một thiết kế quy trình mới lạ, giúp cân bằng giữa tốc độ và độ chính xác cá nhân hóa.

##### 3.1.2. Ưu điểm

AdaDiff giải quyết được các vấn đề mà các phương pháp hiện tại (SOTA) đang gặp phải:

- **Độ bền vững vượt trội trước thay đổi miền:**
  - Đây là điểm mạnh nhất. Khi thay đổi tốc độ chụp ( $R = 4x \rightarrow 8x$ ), thay đổi quỹ đạo lấy mẫu ( $2D \rightarrow 1D$ ), hay thay đổi loại dữ liệu (Đầu gối  $\rightarrow$  Não), các mô hình Conditional (như MoDL) bị suy giảm hiệu năng nghiêm trọng.

AdaDiff vẫn duy trì chất lượng cao nhờ khả năng tự thích ứng.

- **Chất lượng ảnh cao và chi tiết:**
  - Nhờ sử dụng Diffusion Prior, AdaDiff khôi phục được các chi tiết giải phẫu nhỏ và kết cấu (texture) tốt hơn so với các phương pháp GAN (hay bị giả ảnh/hallucination) hoặc các phương pháp truyền thống (bị nhiễu).
- **Nhanh hơn đáng kể so với Diffusion truyền thống:**
  - Nhờ "Adversarial Mapper" cho phép bước nhảy lớn ( $k = 125$ ), AdaDiff chỉ cần khoảng 8 bước để tạo ảnh ban đầu, thay vì 1000 – 4000 bước như DDPM.

### 3.1.3. Hạn chế

Mặc dù rất mạnh, AdaDiff không phải là không có điểm yếu.

- **Thời gian suy luận chậm hơn các mô hình Conditional:**
  - Dù đã nhanh hơn DDPM gốc, nhưng do phải thực hiện vòng lặp tối ưu hóa (Adaptation phase – khoảng 1000 bước lặp) để tinh chỉnh trọng số mạng, AdaDiff chậm hơn nhiều so với các mô hình Conditional (như MoDL chỉ mất 0.05 giây).
- **Tốn kém tài nguyên bộ nhớ:**
  - Để thực hiện pha "Thích ứng" (cập nhật trọng số mạng  $G_\theta$ ), hệ thống phải thực hiện lan truyền ngược (backpropagation) và lưu trữ gradient của mô hình. Điều này tốn VRAM GPU hơn nhiều so với các phương pháp chỉ chạy forward-pass.
- **Thời gian huấn luyện lâu:**
  - Việc huấn luyện AdaDiff phức tạp hơn vì phải huấn luyện cả Generator và Discriminator theo cơ chế GAN, kết hợp với quy trình Diffusion. Nó mất nhiều thời gian hơn so với việc huấn luyện một mạng CNN đơn giản.
- **Mới chỉ kiểm chứng trên 2D:**
  - Bài báo hiện tại thực hiện tái tạo trên từng lát cắt 2D (slice-by-slice). Việc mở rộng lên 3D hoặc 4D (thời gian) để tận dụng thông tin không gian/thời gian vẫn là hướng phát triển tương lai.

## 3.2. Góc nhìn cá nhân và hướng cải tiến

### 3.2.1. Góc nhìn cá nhân

- **Chất lượng hơn Tốc độ:** AdaDiff chấp nhận hi sinh tốc độ (131 giây/ảnh là rất lâu so với 0.05 giây của đối thủ) để đổi lấy sự an toàn. Trong y tế, một vết mờ (blur) do mô hình chạy nhanh gây ra có thể làm lỡ một khối u nhỏ. AdaDiff chọn cách chạy chậm nhưng chắc chắn tái tạo đúng các chi tiết giải phẫu. Đây là tư duy đúng đắn cho các ứng dụng chẩn đoán chuyên sâu (diagnostic imaging).
- **Thiết kế sáng tạo:** Nhóm tác giả đã nhận ra rằng không có một mô hình "one-size-fits-all". Thay vì cố gắng huấn luyện một siêu mô hình để cân tất cả các loại máy MRI, họ chọn cách tạo ra một mô hình "biết học hỏi" và cho phép nó học thích ứng với từng bệnh nhân.
- **Kết hợp các mô hình khác nhau:** Việc nhúng GAN vào trong Diffusion (Adversarial Mapper) để giải quyết vấn đề bước nhảy lớn là một nước đi kỹ thuật khéo léo. Nó phá vỡ sự cứng nhắc của các công thức Gaussian trong DDPM truyền thống.

### 3.2.2. Hướng cải tiến

- **Tăng tốc độ thích ứng bằng "Parameter-Efficient Fine-Tuning" (PEFT).**
  - Vấn đề: Hiện tại, AdaDiff phải cập nhật lại toàn bộ trọng số của Generator ( $\theta_G$ ) trong pha thích ứng. Điều này tốn VRAM và thời gian tính toán lớn.
  - Giải pháp: Áp dụng kỹ thuật LoRA (Low-Rank Adaptation). Thay vì chỉnh sửa toàn bộ mạng thì chỉ thêm các ma trận trọng số nhỏ vào các lớp Attention hoặc Conv và chỉ train các ma trận nhỏ này trong lúc suy luận.
  - Lợi ích: Giảm bộ nhớ GPU, tăng tốc độ hội tụ của pha 2 từ 1000 bước xuống có thể chỉ còn vài chục bước.
- **Mở rộng sang mô hình 3D.**
  - Vấn đề: Bài báo hiện tại xử lý từng lát cắt 2D riêng lẻ (slice-by-slice). Điều này bỏ phí thông tin liên kết giữa các lát cắt và có thể gây ra hiện tượng "nhấp nháy" hoặc không liên tục dọc theo trục Z (trục dọc cơ thể).
  - Giải pháp: Nâng cấp mô hình Generator thành 3D-CNN hoặc Video Diffusion để xử lý cả khối thể tích (volume).

- Lợi ích: Tăng chất lượng tái tạo nhờ tận dụng thông tin không gian 3 chiều, giảm nhiễu tốt hơn.

### 3.3. *Ứng dụng thực tế*

- **Rút ngắn đáng kể thời gian chụp MRI cho bệnh nhân.**
  - Thực tế: Chụp MRI thường mất từ 30-60 phút, gây khó chịu cho bệnh nhân (đặc biệt là người già, trẻ em, hoặc người mắc hội chứng sợ không gian hẹp).
  - Ứng dụng của AdaDiff: Phương pháp này cho phép máy quét thu thập ít dữ liệu hơn (undersampling) nhưng vẫn tái tạo được hình ảnh chất lượng cao. Điều này giúp giảm thời gian bệnh nhân phải nằm trong máy, tăng số lượng ca chụp có thể thực hiện trong ngày.
- **Tăng độ tin cậy khi chuyển đổi giữa các dòng máy và giao thức chụp.**
  - Thực tế: Mỗi bệnh viện dùng một loại máy MRI khác nhau (GE, Siemens, Philips...) với các cài đặt (protocol) khác nhau. Một mô hình AI huấn luyện ở bệnh viện A thường hoạt động kém khi mang sang bệnh viện B (vấn đề Domain Shift).
  - Ứng dụng của AdaDiff: Nhờ khả năng "tự thích ứng" (Prior Adaptation), AdaDiff có thể tự điều chỉnh để làm việc tốt trên dữ liệu của nhiều loại máy và nhiều cấu hình chụp khác nhau mà không cần phải huấn luyện lại từ đầu. Điều này cực kỳ quan trọng để triển khai AI quy mô lớn
- **Nâng cao chất lượng hình ảnh cho các kỹ thuật chụp nhanh.**
  - Thực tế: Khi bác sĩ muốn chụp nhanh (ví dụ trong cấp cứu), họ buộc phải chấp nhận hình ảnh mờ hoặc nhiễu.
  - Ứng dụng của AdaDiff: AdaDiff chứng minh được khả năng tái tạo ảnh sắc nét ngay cả khi dữ liệu đầu vào bị thiếu hụt nghiêm trọng (tăng tốc 8x, 12x), giúp bác sĩ có hình ảnh rõ ràng để ra quyết định nhanh chóng trong tình huống khẩn cấp.